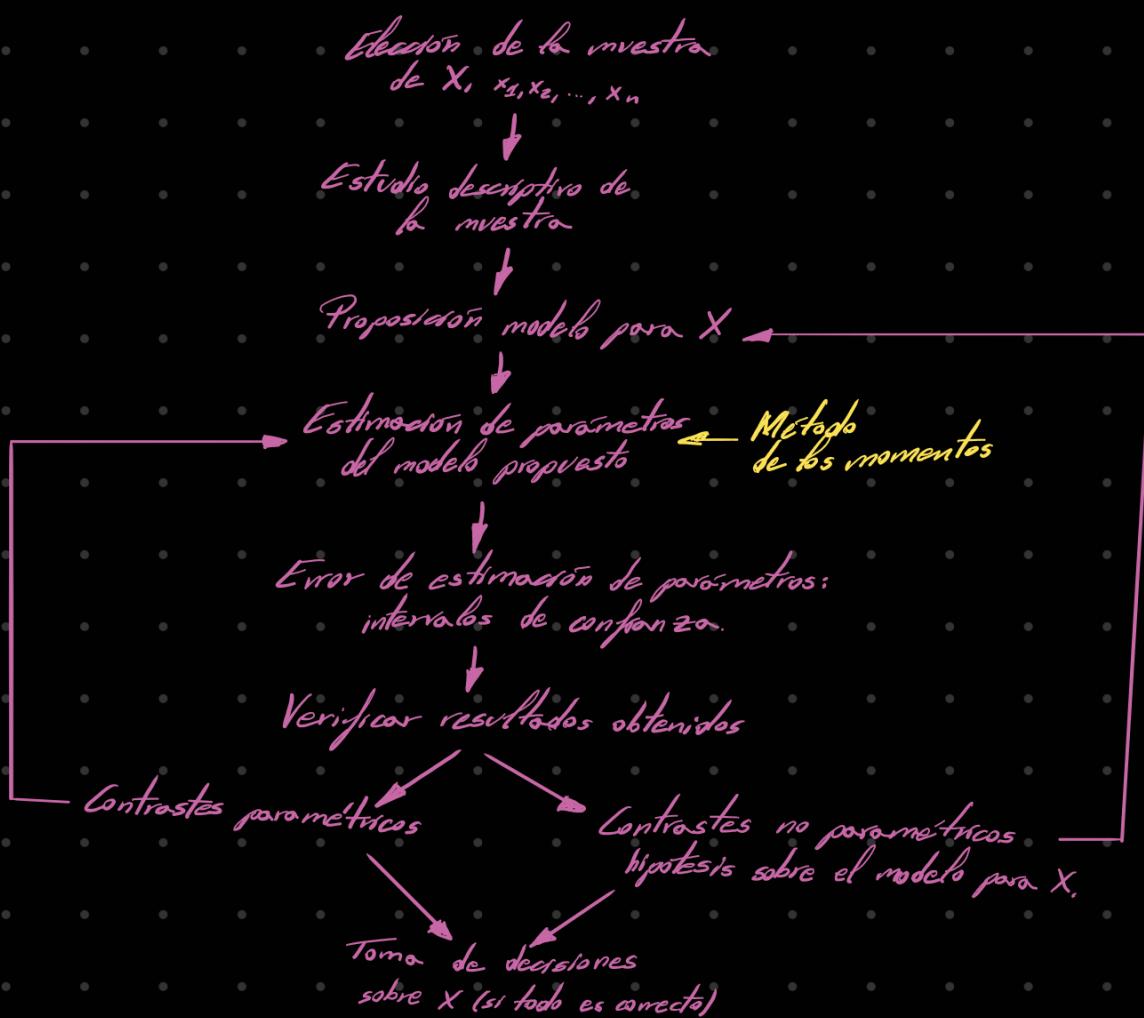


Inferencia estadística. Estimación puntual y estimación por intervalos de confianza.

- 1 - Inferencia estadística \leftarrow Conocer el método estadístico que se usa para obtener conclusiones sobre una variable aleatoria X .
- 2 - Estimación puntual \leftarrow Estimar los parámetros desconocidos del modelo de probabilidad más adecuado para explicar X . \leftarrow Método de los momentos
- 3 - Estimación por intervalos de confianza \leftarrow Al estimar los parámetros se comete un error. Se trata de que sea el menor posible y aceptable.

Inferencia estadística

- Trata de obtener conclusiones sobre una variable aleatoria X medida en una población de individuos. Por eso a X se la suele llamar población.
- Para realizar un estudio sobre una variable aleatoria X , se sigue el método estadístico:



Definiciones

Para la variable aleatoria X que se estudia se supone que tiene distribución F_θ , donde:

- F es conocida
- θ es el parámetro(s) desconocido(s)

Muestra aleatoria simple

Sea X una v.a. con distribución F_θ . Llamarémosla muestra aleatoria simple de tamaño n a n variables X_1, X_2, \dots, X_n que verifican:

- Son independientes.
- X_i tiene la misma distribución que X , $i=1, 2, \dots, n$.

la población

Estadístico o estimador

Finerón de la muestra aleatoria simple, $T(X_1, X_2, \dots, X_n)$ que no dependa del parámetro θ .

- Permite estimar el valor del parámetro desconocido θ .
- Un estadístico $T(X_1, X_2, \dots, X_n) = T$ es una v.a. T porque es una función

$$E[X] = \mu(x)$$

$$V(X) = \sigma^2(x)$$

Estadísticos frecuentes

$$\text{Media muestral } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Varianza muestral } V = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\text{Covarianza muestral } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \rightarrow$$

desviación típica
 $S = \sqrt{S^2}$

$$\text{Máximo y mínimo } \left\{ \begin{array}{l} \max \{X_1, X_2, \dots, X_n\} \\ \min \{X_1, X_2, \dots, X_n\} \end{array} \right.$$

Teorema

Sea X una variable aleatoria con media $E[X]$ y varianza $V(X)$. Sea X_1, X_2, \dots, X_n una muestra aleatoria simple de X . Entonces siempre verifica que:

- Para el estadístico media muestral, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$1.- E[\bar{X}] = E[\bar{X}]$$

$$2.- \frac{V(X)}{n} = V(\bar{X})$$

- Para el estadístico covarianza muestral $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

$$V(X) = E[s^2]$$

Estimación puntual

Sea X una v.a. con distribución F_θ

- Datos de $X: x_1, x_2, \dots, x_n$.
- Considerar la muestra aleatoria simple de X asociada a estos datos X_1, X_2, \dots, X_n .
- Se considera que $X_1 = x_1; X_2 = x_2, \dots; X_n = x_n$.

Para estimar θ se usa un buen estimador $T(\underbrace{X_1, X_2, \dots, X_n}_{\text{variables aleatorias}}) \leftarrow$ con el método de los momentos y se asigna a θ el valor numérico $\hat{\theta}$ obtenido $\hat{\theta} = T(\underbrace{x_1, x_2, \dots, x_n}_{\text{datos}})$
Este valor numérico se llama estimación de θ

Método de los momentos

Caso 1: El modelo de X depende de 1 solo parámetro desconocido $\leftarrow P(\lambda), \dots$

Planteamos una sola ecuación

$$E[X] = \bar{x} \quad ó \quad V(X) = v$$

Caso 2: El modelo de X depende de 2 parámetros desconocidos $\leftarrow N(\mu, \sigma^2), \dots$

Planteamos sistema de dos ecuaciones

$$E[X] = \bar{x} \quad y \quad V(X) = v$$

\bar{x} y v son la media y varianza de los datos.

Distribuciones de probabilidad de algunas variables aleatorias para intervalos de confianza.

Distribución Chi Cuadrado

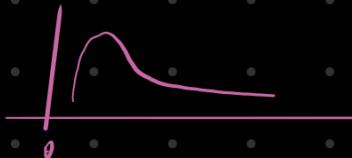
Si X_1, \dots, X_n son v.a. independientes $N(0, 1)$, entonces la variable aleatoria

$$Y = \sum_{i=1}^n X_i^2 \sim \chi_n^2$$

1) El parámetro n es el número de sumandos que intervienen en la definición.

2) La variable chi-cuadrado es una variable de tipo continuo.

Se puede demostrar que $\chi_n^2 = Y(\alpha = \frac{n}{2}, \beta = \frac{1}{2})$. Por tanto, el gráfico de su función de densidad es:



Una variable aleatoria chi cuadrado con n grados de libertad sigue también una distribución Gamma de forma $\alpha = \frac{n}{2}$ y tasa $\beta = \frac{1}{2}$.

Teorema de Fisher

Si X_1, \dots, X_n es una muestra aleatoria simple de una v.a. $X \sim N(\mu, \sigma^2)$

1) Los estadísticos o estimadores

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad y \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2 \text{ son variables aleatorias independientes.}$$

2) La distribución de la variable aleatoria U es

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Distribución t de Student

Si $X \sim N(0, 1)$, $Y \sim \chi_n^2$ son variables independientes, entonces la variable aleatoria Z definida como

$$Z = \frac{X}{\sqrt{\frac{Y}{n}}}$$

sigue una distribución t de student de parámetro n $Z \sim t_n$.

El parámetro de la t_n es el parámetro de la χ_n^2 que interviene en la definición. La distribución t de student es continua, toma valores en todo \mathbb{R} , es simétrica respecto del 0 y su gráfica tiene la misma forma que la $N(0, 1)$.

$$t_n \approx N(0, 1), n \geq 120$$

Teorema

Si X_1, \dots, X_n es una muestra aleatoria simple de una v.a. X con distribución $N(\mu, \sigma)$, entonces, la distribución de la variable aleatoria U es:

$$U = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad y \quad S = \sqrt{s^2} \quad \text{siendo } s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$$

↑
desviación típica

Estimación por intervalos de confianza.

- Sea X una v.a. con distribución F_θ conocida donde θ es el parámetro desconocido. Sea $\{X_1, X_2, \dots, X_n\}$ una muestra simple aleatoria de X .
- Disponemos de $\hat{\theta} = T(X_1, X_2, \dots, X_n)$ un estimador puntual para θ , obtenido por el método de los momentos.

Objetivo en intervalos

Encontrar una cota del error, K , cometido al estimar θ mediante $\hat{\theta}$.
Esta cota K vendrá dada en términos de probabilidad; queremos encontrar K tal que:

$$|\theta - \hat{\theta}| < K \text{ tal que } P(|\theta - \hat{\theta}| < K) \text{ sea alta.}$$

Obtener cota de error, K , es equivalente a obtener un intervalo que contenga al parámetro θ .

$$P(|\theta - \hat{\theta}| < K) = P(\theta \in (\hat{\theta} - K, \hat{\theta} + K))$$

Definición

Sea una v.a. $X \sim F_\theta$. Sea X_1, \dots, X_n una muestra aleatoria simple de X . Llamaremos intervalo de confianza para θ con nivel de confianza $1-\alpha$ a un intervalo (a, b) tal que:

$$P(a < \theta < b) = P(\theta \in (a, b)) = 1 - \alpha$$

- Los extremos del intervalo a y b son variables aleatorias porque dependen de la muestra aleatoria simple tomada para X .

Mejor estimador para el parámetro

$$\mu = E[X]$$

$$X \sim N(\mu, \sigma)$$

$$\text{ó}$$

$$X \text{ cualquier q}$$

$$n \geq 100 \ (\sigma^2 \text{ desconocido})$$

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\sigma^2 = V(X)$$

$$(10' \sigma)$$

$$\text{Solo si } X \sim N(\mu, \sigma)$$

$$\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$$

$$\rho$$

$$\begin{aligned} &\text{Solo si } \\ &X \sim B(1, p) \\ &\text{y} \\ &n \geq 100 \end{aligned}$$

$$\hat{\rho} = \frac{n^{\circ} \text{ elementos con la propiedad}}{\text{tamaño muestra}}$$

Método de la construcción de intervalos de confianza

Método de la cantidad pivotal

1.- Sea $\hat{\theta} = T(X_1, X_2, \dots, X_n) = T$ es el estimador obtenido para θ .

2.- A partir de T se define otra v.a. U que llamaremos pivote.

U tiene que cumplir:

- La distribución de U tiene que ser conocida y no depender de θ .
- En la expresión de U tiene que aparecer el parámetro θ .

3.- Probabilidad alta, $1-\alpha$. Usando la distribución de U encontrar h_1 y h_2 :

$$P(h_1 < U < h_2) = 1 - \alpha$$

4.- Conocidos h_1 y h_2 , despejar θ usando $P(h_1 < U = f(\theta) < h_2) = 1 - \alpha$

$$P(\theta \in (a, b)) = P(a < X_1, \dots, X_n) < \theta < b | X_1, \dots, X_n) = 1 - \alpha$$

| | | | |
|--|---|--|---|
| X | } | X distribución normal | $\left\{ \begin{array}{l} \text{intervalo para la media } \mu \\ \text{intervalo para la varianza } \sigma^2 \end{array} \right.$ |
| X distribución exponencial, $n \geq 100$ | | $\left\{ \begin{array}{l} \text{intervalo aproximado para la media } \mu \\ \text{intervalo aproximado para la proporción } p \end{array} \right.$ | |

Contrastes de hipótesis

• Técnica estadística para decidir si aceptamos o rechazamos la veracidad de cierta hipótesis, en términos probabilísticos.

Se plantea en términos de dos hipótesis (nula y alternativa).

Típos de contrastes

Paramétricas → Hipótesis sobre los valores que puede tomar el parámetro

- Una característica X : la media μ , varianza σ^2 (desviación típica σ) o la proporción p .
- Dos características X e Y : comparar medias μ_X con μ_Y o varianzas σ_X^2 con σ_Y^2 . Prácticas solo

Solo prácticas → No paramétricas → Hipótesis sobre el modelo de distribución

- Contraste Chi-Cuadrado
- Contraste de Kolmogorov-Smirnov

Elementos de un contraste

- Hipótesis nula (H_0) e hipótesis alternativa (H_1)
 - ↑ se considera cierta mientras los datos no muestran lo contrario.
- Nivel de significación α : Máximo error que se permite al tomar la decisión.
- Estadístico del contraste: Sobre el que se toma la decisión
- Región crítica o de rechazo: intervalo o región tal que si el valor $T(x_1, \dots, x_n)$ pertenece a R , se rechazará H_0 .

α = Error de tipo 1 \leftarrow Rechazar H_0 siendo cierta = $P(\text{rechazar } H_0 / H_0 \text{ cierta})$

β = Error de tipo 2 \leftarrow Aceptar H_0 siendo falsa = $P(\text{aceptar } H_0 / H_0 \text{ falsa})$

Estadístico de un contraste

$$\mu = E[X]$$

$$X \sim N(\mu, \sigma^2)$$

X aleatoria, $n \geq 100$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\sigma^2 = V(X)$$

$X \sim \text{Normal}$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$$

$$P$$

 $n \geq 100$

$$p^* = \frac{\text{nº de ts}}{n}$$

Pasos para realizar un contraste de hipótesis.

1.- Planteamiento hipótesis, términos del parámetro (μ, σ^2, p)

2.- Región crítica del contraste, se usa el estadístico del contraste y tiene la misma forma de la hipótesis alternativa.

3.- $\alpha = P(\text{error tipo 1})$ y usando el punto, obtener la región crítica.
Método equivalente contraste con p-valor. \rightarrow

4.- Toma de decisiones, sí o no en la región crítica.
En $p\text{-valor} < \alpha$ se rechaza H_0 .

p-valor

↑ Cuantifica el grado de "seguridad" al tomar la decisión.

Se toma la misma decisión usando región crítica que con el p-valor.

p-valor $\in [0, 1]$ si es mayor a α se acepta H_0 y cuanto más cerca a 1 con mayor confianza.

Planteamientos posibles en contrastes paramétricos

Caso 1

$$H_0: \theta = \theta_0 \text{ ó } \theta \geq \theta_0$$

$$H_1: \theta < \theta_0$$

Caso 2

$$H_0: \theta = \theta_0 \text{ ó } \theta \leq \theta_0$$

$$H_1: \theta > \theta_0$$

Caso 3

Bilateral

$$H_0: \theta = \theta_0$$

$$H_1: \theta \neq \theta_0$$

A mano mediante intervalos de confianza $1-\alpha$

Relación entre los p -valores

$$p\text{-valor}_{\text{caso 1}} = 1 - (p\text{-valor}_{\text{caso 2}})$$

$$\text{Si: } \bar{x} > \mu_0, \sigma_0^2, \rho_0$$

$$p\text{-valor}_{\text{caso 3}} = 2(p\text{-valor}_{\text{caso 2}})$$

$$\text{Si: } \bar{x} < \mu_0, \sigma_0^2, \rho_0$$

$$p\text{-valor}_{\text{caso 3}} = 2(p\text{-valor}_{\text{caso 1}})$$